Redes Neurais Artificiais Lineares e Não Lineares na Classificação de uma Espiral e no Reconhecimento Facial

João Lucas Lima Maia
Ciência da Computação
Universidade de Fortaleza
(UNIFOR)
Fortaleza, Brasil
joaolucaslimamaia@gmail.com

***Resumo*—Este trabalho implementa, apenas com numpy, o Perceptron Simples, o ADALINE e o Perceptron de Múltiplas Camadas (MLP) e os avalia em dois problemas. No primeiro, a classificação binária de uma espiral bidimensional (1400 amostras), a validação por amostragem aleatória com 500 rodadas resultou em acurácia média de 71,80% para o Perceptron, 78,86% para o ADALINE e 99,24% para a MLP 5-5, o que confirma que os modelos lineares não resolvem um problema não linearmente separável. Também foram identificados o underfitting de uma MLP subdimensionada e o overfitting de uma superdimensionada. No segundo, o reconhecimento de 20 pessoas em 640 imagens reduzidas para 30 × 30 pixels, a validação por Monte Carlo foi executada com R = 10 e com R = 100 rodadas, por causa de uma divergência no enunciado. Com R = 100, as acurácias médias foram 97,80% (Perceptron), 98,03% (ADALINE) e 98,27% (MLP 50-50); com R = 10, 97,03%, 97,81% e 97,89%. Com 900 atributos e 512 imagens de treino, o problema torna-se quase linearmente separável, e os três modelos têm desempenho próximo.**

Palavras-chave—Perceptron Simples, ADALINE, perceptron de múltiplas camadas, retropropagação, reconhecimento facial, validação Monte Carlo

I. Introdução

Redes neurais artificiais são modelos inspirados no funcionamento do cérebro que aprendem a partir de exemplos [1]. Este trabalho compara três delas: o Perceptron Simples [2] e o ADALINE [3], que são modelos lineares (um único neurônio por saída, com fronteira de decisão linear), e o Perceptron de Múltiplas Camadas (MLP) treinado por retropropagação do erro [4], que é não linear. Na primeira etapa, os modelos são validados em um problema bidimensional sintético de duas classes com formato de espiral. Na segunda, são aplicados ao reconhecimento de 20 pessoas a partir de imagens faciais [6]. Em ambas as etapas o desempenho é estimado por validação com várias partições aleatórias treino/teste.

II. Metodologia

A. Ambiente de desenvolvimento e reprodutibilidade

As implementações foram escritas em Python 3.12 usando somente as bibliotecas permitidas: numpy (álgebra linear, leitura do CSV, sorteios e estatísticas), matplotlib e seaborn (gráficos; o seaborn foi usado apenas para desenhar heatmaps e violin plots) e opencv-python (apenas leitura e redimensionamento das imagens). A separação treino/teste, a normalização, a codificação one-hot, a matriz de confusão e as métricas foram implementadas pela equipe. O código está dividido em *modelos.py* (classes Perceptron Simples, ADALINE e MLP, com os métodos *fit* e *predict* e o histórico do EQM por época), *utils.py* (funções de apoio) e *etapa1.py*/*etapa2.py* (experimentos). Todos os sorteios usam um gerador do numpy com semente fixa (42), o que torna os resultados reprodutíveis.

B. Organização e pré-processamento dos dados

1) Etapa 1: O arquivo spiral_d.csv possui N = 1400 amostras com p = 2 atributos (colunas 1 e 2) e o rótulo na coluna 3. A inspeção dos rótulos mostrou que eles já estão no formato bipolar {−1, +1}, com 1000 amostras da classe +1 e 400 da classe −1 (71,4% e 28,6%; classes desbalanceadas). A classe +1 foi adotada como positiva no cálculo da sensibilidade e da especificidade. Seguindo a notação dos slides da disciplina [7], cada amostra é uma coluna de X e a primeira linha é a entrada de bias, constante e igual a −1:

$$X = \left[x_1\ x_2 \cdots x_N\right] \in \mathbb{R}^{(p+1)\times N},\quad x(t) = \left[-1,\ x_1(t),\ x_2(t)\right]^T \tag{1}$$

Assim, na Etapa 1, X tem dimensão 3 × 1400 e o vetor de rótulos d tem 1400 posições.

2) Etapa 2: A pasta RecFac contém 20 subpastas, uma por pessoa, com 32 imagens PNG de 120 × 128 pixels cada (640 imagens). Cada pessoa aparece em quatro poses (esquerda, direita, frente e para cima), quatro expressões e com ou sem óculos escuros. No repositório a pasta está aninhada (RecFac/RecFac/<pessoa>), e o código desce automaticamente até o nível que contém as pessoas. O nome de cada subpasta é usado como rótulo. As imagens foram lidas em escala de cinza (cv2.imread) e redimensionadas para 30 × 30 pixels com interpolação por área (cv2.INTER_AREA), que calcula a média dos pixels de cada região e evita serrilhado. Entre as opções do enunciado (30 × 30, 40 × 40, 50 × 50 e 80 × 80), escolheu-se a menor: ela ainda preserva o contorno do rosto, o cabelo e a presença dos óculos (Fig. 1) e reduz o custo do treinamento, que é repetido 110 vezes (R = 10 e R = 100) para cada modelo. Cada imagem foi vetorizada em 900 valores, de modo que X tem dimensão 901 × 640. Os rótulos foram codificados em one-hot bipolar: a pessoa k recebe um vetor com +1 na posição k e −1 nas outras 19 posições; com as pessoas em ordem alfabética (an2i, at33, boland, bpm, ch4f, …), a mesma do enunciado, Y tem dimensão 20 × 640:

$$y_{an2i} = [+1,\ -1,\ -1, \cdots,\ -1]^T,\quad Y \in \mathbb{R}^{C\times N},\quad C = 20 \tag{2}$$



Fig. 1. Uma imagem de cada uma das 20 pessoas após a conversão para escala de cinza e o redimensionamento para 30 × 30 pixels.

3) Normalização: Antes do treinamento, cada atributo foi normalizado para o intervalo [−1, 1] por min-max:

$$x' = 2\,\frac{x - x_{mín}}{x_{máx} - x_{mín}} - 1 \qquad (3)$$

Esse intervalo foi escolhido por coincidir com a faixa da tangente hiperbólica, com os rótulos bipolares e com o valor da entrada de bias, deixando todas as entradas na mesma escala. O mínimo e o máximo de cada atributo são calculados somente com as amostras de treino de cada rodada e depois aplicados ao teste, para que nenhuma informação do teste participe do treinamento. Pixels constantes no treino recebem o valor 0, evitando divisão por zero.

C. Modelos de redes neurais

Os três modelos recebem $X \in \mathbb{R}^{(p+1)\times N}$ e a matriz de rótulos $D \in \mathbb{R}^{C\times N}$, com C = 1 na Etapa 1 e C = 20 na Etapa 2. Em todos eles o treinamento é acompanhado pelo erro quadrático médio (EQM) de cada época,

$$EQM = \frac{1}{2N}\sum_{t=1}^{N}\sum_{j=1}^{C}\left(d_j(t) - y_j(t)\right)^2 \qquad (4)$$

que também é calculado no conjunto de teste, apenas para desenhar a curva de aprendizado. O teste nunca influencia o ajuste dos pesos nem o critério de parada. Todos os modelos param, no máximo, ao atingir um número máximo de épocas.

1) Perceptron Simples: Para cada amostra calcula-se o potencial de ativação e a saída pela função degrau bipolar [2]:

$$u(t) = w^T x(t), \quad y(t) = \{+1, \quad se\ u(t) \geq 0 \quad -1, \quad se\ u(t) < 0 \qquad (5)$$

Quando a saída difere do rótulo desejado d(t), os pesos são corrigidos pela regra de aprendizado do Perceptron:

$$w \leftarrow w + \eta(d(t) - y(t))x(t) \qquad (6)$$

Os pesos partem de zero, como nos slides. O algoritmo clássico repete as épocas até que uma época inteira ocorra sem erros, o que nunca acontece com dados não linearmente separáveis, como a espiral. Por isso, conforme exige o enunciado, foi acrescentado o critério de parada por número máximo de épocas. Uma consequência da inicialização nula é que a fronteira obtida não depende de η: todas as correções são múltiplos de η, então w é sempre o mesmo vetor multiplicado por η e o sinal de w^Tx não muda. Na Etapa 2 são usados 20 perceptrons independentes ($W \in \mathbb{R}^{901\times 20}$), cada um treinado para responder +1 apenas para a sua pessoa. O EQM do Perceptron é calculado sobre a saída do degrau; cada amostra classificada errada contribui com 2/N.

2) ADALINE: O ADALINE [3] tem a mesma estrutura, mas o erro é medido na saída linear u(t), e os pesos são ajustados pela regra delta (LMS), que é um passo de gradiente descendente sobre o EQM:

$$w \leftarrow w + \eta(d(t) - u(t))x(t) \qquad (7)$$

O treinamento é feito amostra a amostra, como nos slides, e termina quando a variação do EQM entre duas épocas consecutivas fica abaixo da precisão ε, ou ao atingir o número máximo de épocas:

$$\left|EQM_{\ atual} - EQM_{\ anterior}\right| \leq \varepsilon \qquad (8)$$

Depois de treinado, o ADALINE classifica pelo degrau bipolar aplicado a u (Etapa 1) ou pelo argmax de u (Etapa 2). A regra LMS só converge se a taxa de aprendizado respeitar

$$0 < \eta < \frac{2}{\lambda_{máx}}, \quad R = \frac{1}{N}XX^T \qquad (9)$$

em que $\lambda_{máx}$ é o maior autovalor da matriz de correlação das entradas [1]. Esse limite foi usado para delimitar os valores de η investigados na Etapa 2.

3) Perceptron de Múltiplas Camadas: A MLP usa a tangente hiperbólica em todos os neurônios (ocultos e de saída), cuja derivada pode ser escrita em função da própria saída: $g'(i) = 1 - g(i)^2$. Sendo $W^{(l)}$ a matriz de pesos da camada l, com q_l linhas e $q_{l-1} + 1$ colunas (a primeira associada ao bias), a fase *forward* calcula, para l = 1, …, L,

$$i^{(l)} = W^{(l)}y^{(l-1)}, \quad y^{(l)} = tanh\left(i^{(l)}\right) \qquad (10)$$

com $y^{(0)} = X$ e uma linha de −1 acrescentada à saída de cada camada oculta (bias da camada seguinte). A fase *backward* (retropropagação [4]) calcula os gradientes locais da saída para a entrada,

$$\delta^{(L)} = \left(1 - y^{(L)} \odot y^{(L)}\right) \odot \left(D - y^{(L)}\right) \qquad (11)$$

$$\delta^{(l)} = \left(1 - y^{(l)} \odot y^{(l)}\right) \odot \left(\tilde{W}^{(l+1)T}\delta^{(l+1)}\right) \qquad (12)$$

em que ⊙ é o produto elemento a elemento e $\tilde{W}$ é a matriz de pesos sem a coluna do bias. Por fim, os pesos são atualizados por gradiente descendente:

$$W^{(l)} \leftarrow W^{(l)} + \frac{\eta}{N}\delta^{(l)}y^{(l-1)T} \qquad (13)$$

Os slides apresentam o *backpropagation* amostra a amostra. Aqui as N amostras de treino são propagadas juntas, como colunas de uma matriz, e o gradiente usado é a média dos gradientes individuais (gradiente descendente em lote). A regra de atualização é a mesma, apenas acumulada ao longo da época, e corresponde ao gradiente exato do EQM de treino. Essa adaptação permite usar operações matriciais do numpy e tornou viável repetir o treinamento 500 vezes na Etapa 1. A MLP para quando o EQM de treino fica abaixo da precisão ε, ou ao atingir o número máximo de épocas.

Os pesos do ADALINE e da MLP são sorteados de uma distribuição uniforme

$$w \sim U\left(-\frac{1}{\sqrt{n_e}}, \quad \frac{1}{\sqrt{n_e}}\right) \qquad (14)$$

em que n_e é o número de entradas do neurônio, incluindo o bias. Os slides sugerem valores pequenos, tipicamente em [−0,5; 0,5]. Para a espiral (n_e = 3) o limite é 0,577, praticamente a faixa clássica; para as imagens (n_e = 901) ele

cai para 0,033. Isso impede que o potencial de ativação inicial seja grande demais e sature a tangente hiperbólica, situação em que $g'(i) \approx 0$ e o aprendizado praticamente para [5].

4) Regra de decisão: Na Etapa 1, a classe prevista é o sinal da saída (degrau bipolar). Na Etapa 2, é o índice do neurônio de saída com maior valor:

$$\hat{c}(t) = arg\,max_{j=1,\ldots,C}\, y_j(t) \qquad (15)$$

No Perceptron, várias saídas do degrau podem valer +1 ao mesmo tempo (ou nenhuma). Por isso o argmax é aplicado ao potencial u, que é a saída do neurônio antes do degrau.

D. Escolha dos hiperparâmetros

Os hiperparâmetros foram escolhidos por busca em grade. Cada configuração foi avaliada em partições treino/validação (80/20) sorteadas com uma semente diferente da usada na validação final (cinco partições na Etapa 1 e três na Etapa 2, cujo treinamento é mais caro) e comparada pela média da métrica de validação.

1) Etapa 1: Para o Perceptron testou-se $\eta \in \{0{,}001;\ 0{,}01;\ 0{,}1;\ 1\}$. Como previsto pela inicialização nula, as quatro taxas resultaram exatamente na mesma acurácia, e $\eta = 0{,}01$ foi mantido. O limite de 100 épocas foi fixado observando que, na espiral, o EQM do Perceptron apenas oscila, sem tendência de queda. Para o ADALINE testou-se $\eta \in \{10^{-4};\ 5\cdot10^{-4};\ 10^{-3};\ 5\cdot10^{-3};\ 10^{-2}\}$, com $\varepsilon = 10^{-6}$ e no máximo 500 épocas, escolhendo o η de menor EQM de validação, que é a função que o ADALINE minimiza. Para a MLP foram testadas seis topologias (uma camada oculta com 5, 10 ou 20 neurônios; duas camadas com 5-5, 10-10 ou 20-20) e três taxas ($\eta \in \{0{,}5;\ 1;\ 2\}$), com no máximo 2000 épocas e $\varepsilon = 10^{-3}$. Adotou-se um critério de parcimônia: entre as configurações cuja acurácia média de validação fica a até 0,25 ponto percentual da melhor (cerca de 3 das 1400 amostras de validação), escolhe-se a de menor número de pesos, o que reduz o custo e o risco de overfitting. A precisão $\varepsilon = 10^{-3}$ corresponde a um erro RMS por saída de cerca de 0,045 ($\sqrt{(2\cdot10^{-3})}$), ou seja, saídas da tanh já muito próximas de ±1. Continuar o treinamento a partir daí apenas aumentaria a magnitude dos pesos, sem ganho de classificação.

2) Etapa 2: Na Etapa 2 foi seguida a mesma lógica, aproveitando a experiência da Etapa 1. (i) O Perceptron foi mantido com $\eta = 0{,}01$ e 100 épocas; como $p = 900$ é maior que o número de amostras de treino ($N = 512$), os dados de treino são linearmente separáveis e ele converge em poucas épocas. (ii) Para o ADALINE, o maior autovalor de R é $\lambda_{máx} = 139{,}1$, o que exige $\eta < 0{,}0144$. Foram testados $\eta \in \{5\cdot10^{-4};\ 10^{-3};\ 2\cdot10^{-3}\}$ com $\varepsilon = 10^{-3}$ e $\eta = 10^{-3}$ com $\varepsilon = 10^{-4}$, escolhendo a maior acurácia de validação e, em caso de empate (até 0,25 p.p.), a mais rápida. (iii) Para a MLP, a taxa de aprendizado precisou ser bem menor que na espiral. Em testes preliminares, $\eta \geq 0{,}5$ levou as 20 saídas à saturação em −1 (EQM = 2), porque 19 dos 20 alvos de cada amostra valem −1 e o gradiente empurra rapidamente todas as saídas para esse valor. Foram então testadas as topologias 20, 50, 100 e 50-50 com $\eta \in \{0{,}05;\ 0{,}1\}$, no máximo 1500 épocas e $\varepsilon = 10^{-3}$, aplicando o mesmo critério de parcimônia. A Tabela I resume os valores finais.

TABELA I. HIPERPARÂMETROS ESCOLHIDOS

Modelo / etapa	Neurônios ocultos	η	Épocas máx.	ε
Perceptron – E1	—	0,01	100	—
ADALINE – E1	—	0,0001	500	10^{-6}
MLP – E1	5-5	2	2000	10^{-3}
Perceptron – E2	—	0,01	100	—
ADALINE – E2	—	0,002	300	10^{-3}
MLP – E2	50-50	0,1	1500	10^{-3}

Em todas as MLPs a camada de saída tem a quantidade de neurônios igual ao número de classes codificadas: 1 neurônio na Etapa 1 (saída bipolar) e 20 neurônios na Etapa 2 (one-hot).

E. Estudo de underfitting e overfitting

Para identificar underfitting e overfitting, a MLP foi treinada com três topologias nas mesmas cinco partições 80/20 (uma única partição poderia ser enganosa, por exemplo, por uma inicialização ruim): (i) subdimensionada, 2-2-1 (uma camada oculta com 2 neurônios e 9 pesos), $\eta = 2$ e até 2000 épocas; (ii) adequada, a topologia 2-5-5-1 escolhida na busca (51 pesos); (iii) superdimensionada, 2-60-60-60-1 (três camadas ocultas com 60 neurônios e 7561 pesos), $\eta = 1$, 15000 épocas e $\varepsilon = 0$, isto é, sem parada antecipada, forçando a rede a continuar ajustando o treino. Para cada caso foram calculadas, no teste, a acurácia, a sensibilidade e a especificidade (média e desvio-padrão das cinco partições) e, para a primeira partição, a matriz de confusão, a curva de aprendizado (EQM de treino e de teste por época) e a fronteira de decisão.

F. Estratégia de validação e métricas

1) Etapa 1: Foi usada validação por amostragem aleatória com $R = 500$ rodadas. Em cada rodada os índices das 1400 amostras são embaralhados; as primeiras 1120 (80%) formam o treino e as 280 restantes (20%) o teste. A normalização é recalculada e os três modelos são treinados do zero com os hiperparâmetros da Tabela I. No teste foram medidas a acurácia, a sensibilidade e a especificidade:

$$Acc = \frac{VP+VN}{VP+VN+FP+FN},\ Sens = \frac{VP}{VP+FN},\ Esp = \frac{VN}{VN+FP} \qquad (16)$$

VP, VN, FP e FN são os verdadeiros/falsos positivos/negativos, obtidos da matriz de confusão. A matriz é calculada pela equipe, somando 1 na célula (classe real, classe prevista) de cada amostra; as linhas correspondem à classe real e as colunas à prevista, e o seaborn é usado apenas para desenhar o heatmap. Para cada modelo e métrica foram identificadas a rodada de maior e a de menor valor (em caso de empate, a primeira rodada em que o valor ocorre), e para elas foram plotadas a matriz de confusão e a curva de aprendizado. Ao final das R rodadas calcularam-se a média, o desvio-padrão amostral, o maior e o menor valor de cada métrica,

$$\bar{a} = \frac{1}{R}\sum_{k=1}^{R} a_k,\quad s = \sqrt{\frac{1}{R-1}\sum_{k=1}^{R}\left(a_k - \bar{a}\right)^2} \qquad (17)$$

apresentados em uma tabela por métrica e complementados por boxplots e violin plots.

2) Etapa 2: Foi usada validação por simulações de Monte Carlo com a mesma partição 80/20 (512 imagens de treino e 128 de teste por rodada), tendo a acurácia como métrica. O enunciado apresenta uma divergência quanto ao número de rodadas: o item 5 define $R = 10$, enquanto o item 7 pede as estatísticas "ao final das R = 100 rodadas". Como não é possível saber qual valor era o pretendido, a equipe optou por executar e reportar as duas configurações. O script recebe R como parâmetro e grava as saídas em pastas separadas (etapa2_R10 e etapa2_R100). Como a semente é a mesma, as 10 rodadas da configuração $R = 10$ coincidem com as 10 primeiras da configuração $R = 100$, e a comparação entre as duas mostra exatamente o efeito de aumentar o número de rodadas sobre as estimativas. Para cada modelo e configuração foram geradas as matrizes de confusão 20 × 20 e as curvas de aprendizado das rodadas de maior e de menor acurácia. Para identificar as pessoas mais e menos reconhecidas, as matrizes de todas as rodadas foram somadas e calculou-se a taxa de acerto de cada pessoa (diagonal dividida pelo total da linha).

G. Resumo das adaptações em relação à formulação dos

slides

- **Critério de parada por épocas no Perceptron**: exigido pelo enunciado, pois o algoritmo original não termina em dados não linearmente separáveis.
- **Gradiente descendente em lote na MLP**: a mesma regra do backpropagation, calculada de uma vez para todas as amostras (média dos gradientes); permite vetorizar e executar 500 rodadas em tempo razoável.
- **Pesos iniciais uniformes e pequenos** no ADALINE e na MLP, em $U(-1/\sqrt{n_e},\ 1/\sqrt{n_e})$: preserva a escala clássica (±0,5) na espiral e evita a saturação da tanh com 900 entradas.
- **Normalização min-max em [−1, 1] calculada só com o treino** de cada rodada: mesma faixa da tanh, dos rótulos e do bias; sem vazamento de informação do teste.
- **Argmax do potencial u no Perceptron multiclasse**: desempata os casos em que várias saídas do degrau valem +1 (ou nenhuma).
- **ε = 0 e 15000 épocas na topologia superdimensionada**: desliga a parada antecipada para tornar o overfitting observável.
- **BLAS com uma única thread**: apenas desempenho; com matrizes pequenas, uma thread foi mais rápida e garante resultados idênticos a cada execução.

III. Resultados

A. Etapa 1 – classificação da espiral

1) Visualização inicial: A Fig. 2 mostra o gráfico de espalhamento dos dados originais. As duas classes formam braços de espiral entrelaçados: a classe −1 aparece tanto no anel externo quanto no centro, envolvida pela classe +1. Nenhuma reta separa as classes, portanto o problema não é linearmente separável. Por isso espera-se que o Perceptron Simples e o ADALINE, cuja fronteira de decisão é um hiperplano, tenham desempenho limitado, e que apenas a MLP consiga modelar a fronteira curva. Também se nota o desbalanceamento: um classificador trivial que sempre responde +1 já acertaria 71,4% das amostras, valor que serve de referência para as acurácias.

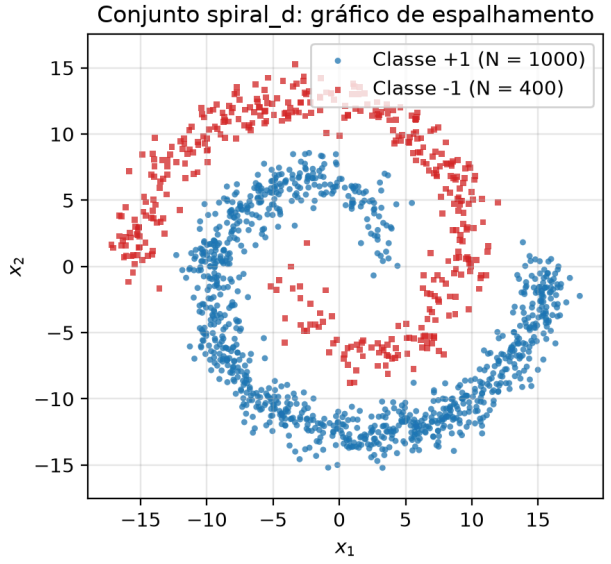


Fig. 2. Gráfico de espalhamento do conjunto spiral_d (atributos originais, antes da normalização).

2) Escolha dos hiperparâmetros: No Perceptron, as quatro taxas testadas produziram exatamente a mesma acurácia média de validação (75,43%), confirmando que, com pesos iniciais nulos, η não altera a fronteira. No ADALINE (Fig. 3), todas as taxas convergiram para praticamente o mesmo EQM de validação (entre 0,2847 e 0,2855) e a mesma acurácia (cerca de 78,1%). O que muda é a velocidade: com $\eta = 10^{-4}$ foram necessárias 171 épocas, e com $\eta = 10^{-2}$ apenas 5. Isso mostra que o limite do ADALINE é o modelo linear, e não o treinamento. Pelo critério do menor EQM de validação, escolheu-se η = 0,0001, cuja convergência é a mais suave. Na MLP (Fig. 4), as taxas maiores foram melhores dentro do limite de 2000 épocas, porque o gradiente em lote dá passos médios pequenos. Duas camadas ocultas também superaram uma: a rede 5-5, com 51 pesos, foi melhor que a de uma camada com 20 neurônios, que tem 81 pesos (99,64% contra 98,14%). A melhor acurácia de validação foi 99,64%, obtida pela própria topologia 5-5 com η = 2, que também é a de menos pesos (51) entre as configurações dentro da tolerância de parcimônia e por isso foi a escolhida.

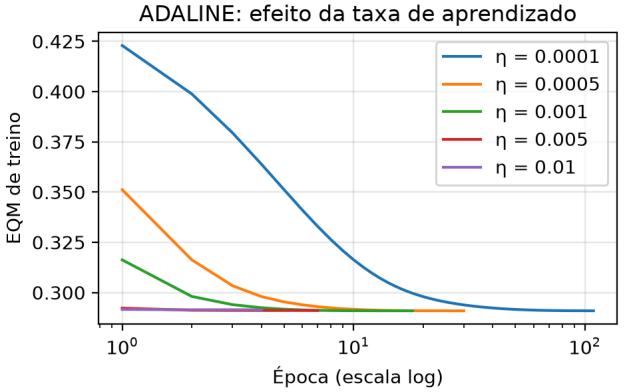


Fig. 3. ADALINE: EQM de treino por época para cada taxa de aprendizado (primeira partição da busca).

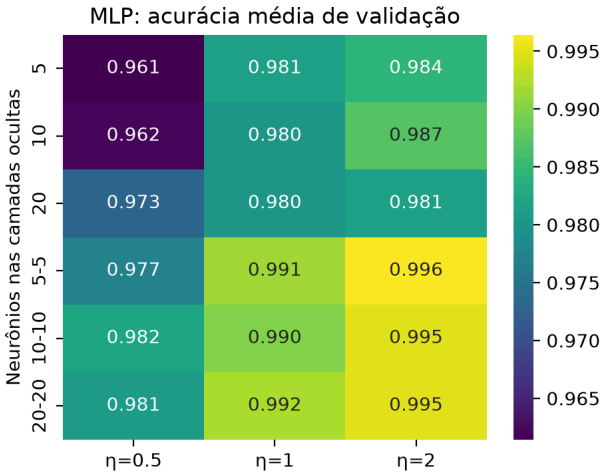


Fig. 4. MLP: acurácia média de validação para cada topologia e taxa de aprendizado.

3) Underfitting e overfitting da MLP: A Tabela II resume as três topologias (média ± desvio-padrão nas cinco partições), e as Figs. 5 e 6 mostram as curvas de aprendizado, as fronteiras de decisão e as matrizes de confusão da primeira partição.

Tabela II. MLP: topologias sub e superdimensionadas (média ± desvio, 5 partições)

Métrica	Sub 2-2-1	Adequada 2-5-5-1	Super 2-60-60-60-1
Nº de pesos	9	51	7561
Épocas (média)	2000	2000	15000
EQM treino	0,2089 ± 0,0411	0,0064 ± 0,0063	0,00609 ± 0,01358
EQM teste	0,2293 ± 0,0530	0,0074 ± 0,0051	0,0132 ± 0,0167
Acurácia treino	0,8682 ± 0,0379	0,9971 ± 0,0039	0,9970 ± 0,0068
Acurácia teste	0,8471 ± 0,0499	0,9957 ± 0,0030	0,9921 ± 0,0096
Sensibilidade	0,9888 ± 0,0077	0,9950 ± 0,0035	0,9960 ± 0,0041
Especificidade	0,5191 ± 0,1426	0,9972 ± 0,0062	0,9818 ± 0,0279
Tempo médio (s)	0,1	0,4	62,2
Partições com EQM treino < 10^{-3}	0 de 5	0 de 5	4 de 5

A rede subdimensionada (2-2-1) apresenta underfitting. O EQM fica alto e praticamente igual no treino (0,2089) e no teste (0,2293), a acurácia de treino (86,82%) é tão baixa quanto a de teste, e as curvas se estabilizam cedo (Fig. 5). Com apenas dois neurônios ocultos, a fronteira é quase uma reta: a rede não tem capacidade nem para aprender o treino, ou seja, o erro é de viés, e não de variância. Ela acerta quase toda a classe majoritária (sensibilidade de 98,88%), mas classifica grande parte da classe −1 como +1 (especificidade de 51,91%).

A topologia adequada (2-5-5-1) alcança EQM baixo e próximo no treino e no teste (0,0064 e 0,0074) e acurácia de teste de 99,57% ± 0,30%, com uma fronteira suave que acompanha os braços da espiral.

A rede superdimensionada (2-60-60-60-1, 7561 pesos), treinada por 15000 épocas sem parada antecipada, memorizou o conjunto de treino em 4 das 5 partições, com EQM de treino da ordem de 10^{-5} e 100% de acurácia de treino. A Fig. 5 mostra a assinatura do overfitting na primeira partição. O EQM de teste atinge o mínimo no início do treinamento (linha pontilhada), depois volta a subir e estaciona, enquanto o EQM de treino continua caindo até $2{,}0\cdot10^{-5}$. Ao final, o erro de teste é cerca de 387 vezes o de treino. Todas as épocas após o mínimo servem apenas para ajustar o treino. Em 2 das partições memorizadas essa razão foi grande (387 e 1604 vezes). Nas outras, as amostras de teste caíram em regiões onde a fronteira memorizada coincide com a verdadeira, o que é possível porque a espiral tem pouco ruído. Na partição 2, a rede nem chegou a memorizar: ficou presa em um platô do EQM (0,030), dificuldade típica de redes profundas treinadas por gradiente descendente simples. Em média, a rede superdimensionada teve acurácia de teste menor que a adequada (99,21% contra 99,57%) e desvio-padrão 3 vezes maior. Essa variabilidade entre partições é característica de um modelo com excesso de capacidade, cujo resultado depende muito de quais amostras ficaram no treino. Além disso, ela exige 148 vezes mais pesos e cerca de 152 vezes mais tempo de treinamento. Em dados mais ruidosos, a memorização incluiria o ruído e a perda de acurácia seria ainda maior.

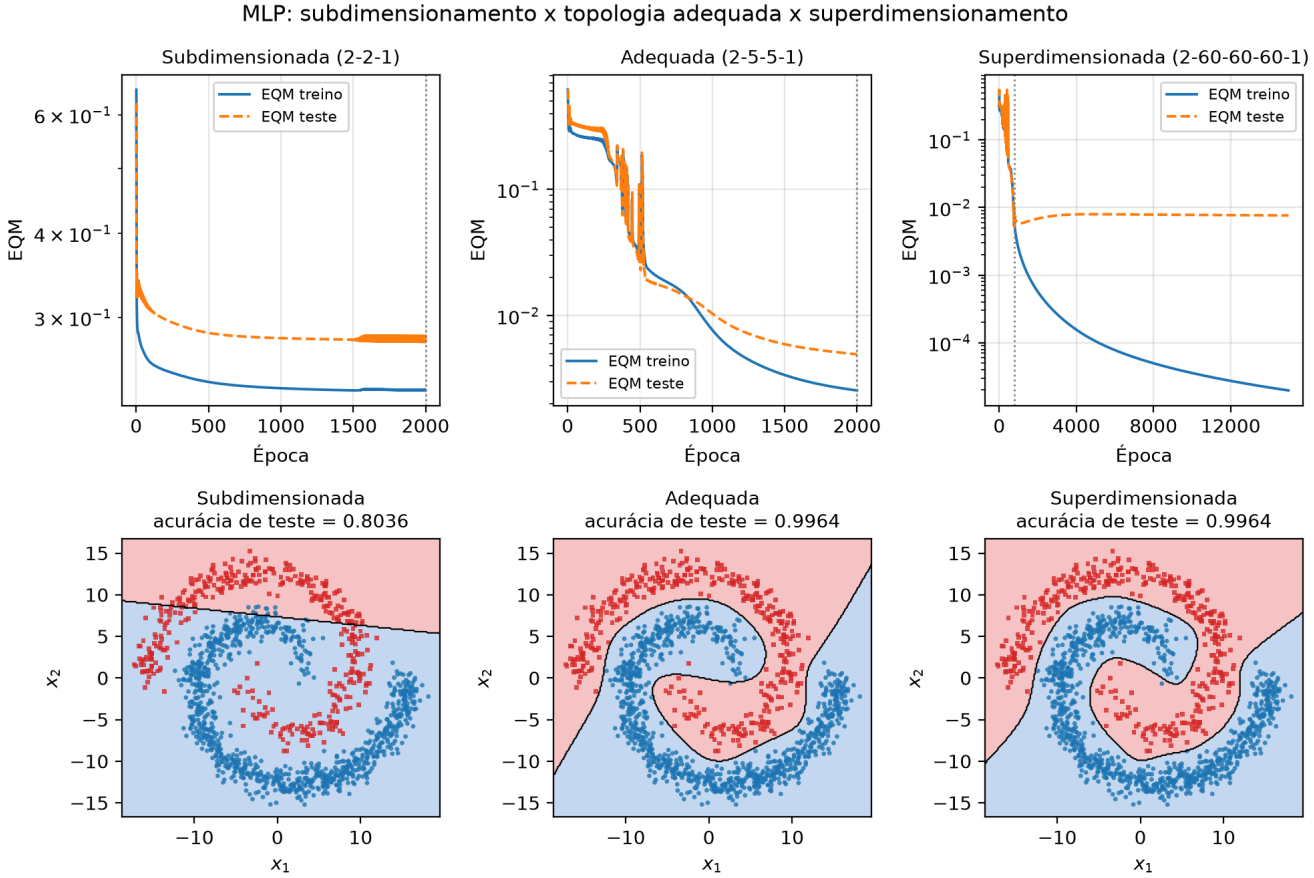


Fig. 5. MLP subdimensionada, adequada e superdimensionada (primeira partição). Linha de cima: curvas de aprendizado em escala logarítmica (a linha pontilhada marca a época de menor EQM de teste). Linha de baixo: fronteiras de decisão.

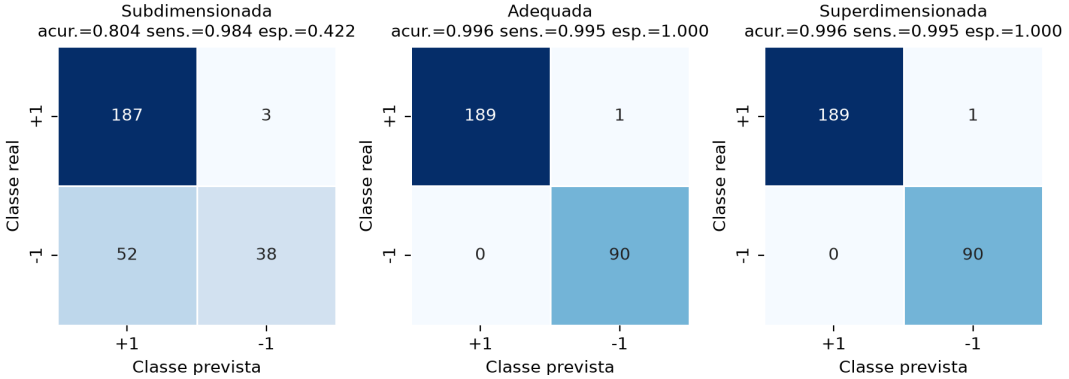


Fig. 6. Matrizes de confusão no teste das três topologias (primeira partição). Linhas: classe real; colunas: classe prevista.

4) Validação com R = 500 rodadas: As Tabelas III, IV e V trazem as estatísticas das 500 rodadas para cada métrica, e a Fig. 7 mostra as distribuições em boxplots e violin plots.

TABELA III. ACURÁCIA NAS 500 RODADAS (ETAPA 1)

Modelo	Média	Desvio-padrão	Maior valor	Menor valor
Perceptron Simples	0,7180	0,1008	0,8857	0,2500
ADALINE	0,7886	0,0234	0,8536	0,7107
MLP	0,9924	0,0077	1,0000	0,9321

TABELA IV. SENSIBILIDADE NAS 500 RODADAS (ETAPA 1)

Modelo	Média	Desvio-padrão	Maior valor	Menor valor
Perceptron Simples	0,8033	0,2192	1,0000	0,0000
ADALINE	0,8834	0,0267	0,9521	0,7953
MLP	0,9959	0,0048	1,0000	0,9704

TABELA V. ESPECIFICIDADE NAS 500 RODADAS (ETAPA 1)

Modelo	Média	Desvio-padrão	Maior valor	Menor valor
Perceptron Simples	0,5035	0,2827	1,0000	0,0000
ADALINE	0,5526	0,0509	0,7108	0,4217
MLP	0,9836	0,0237	1,0000	0,7733

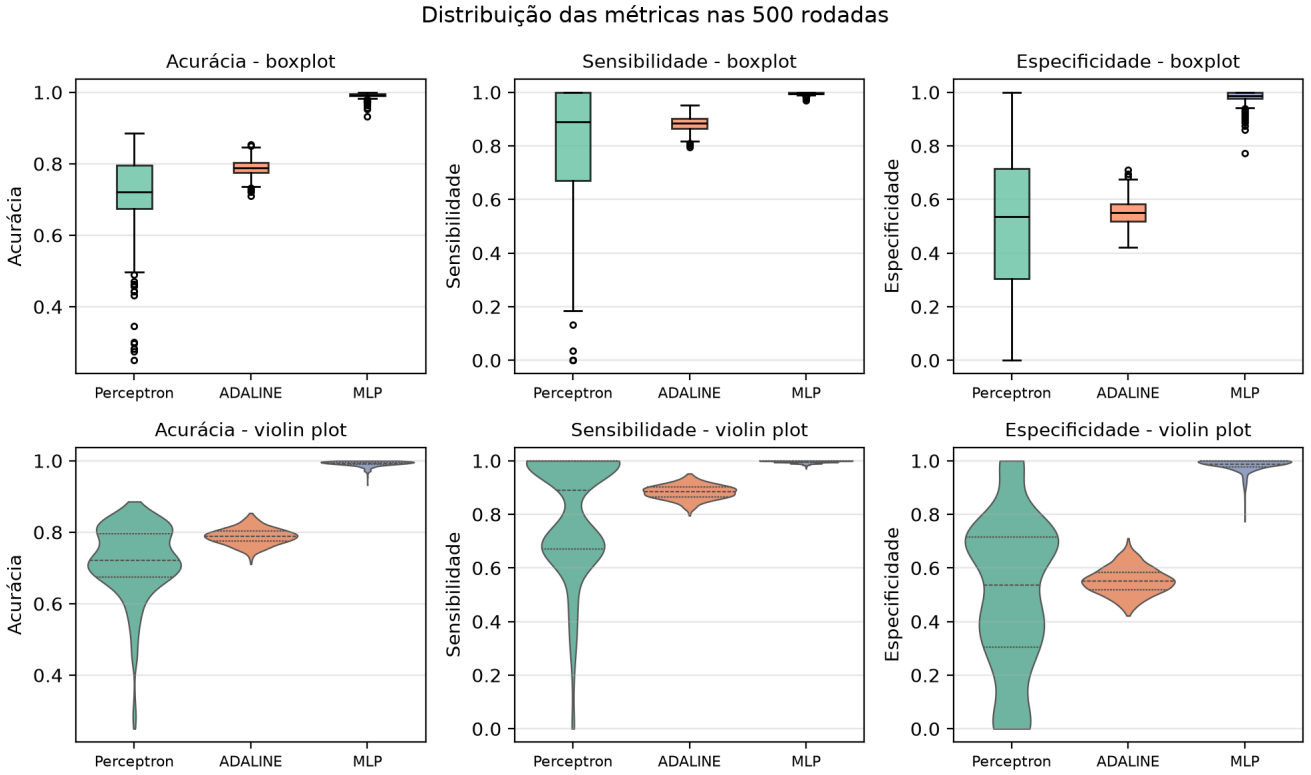


Fig. 7. Distribuição da acurácia, da sensibilidade e da especificidade nas 500 rodadas (boxplots acima e violin plots abaixo).

A MLP teve acurácia média de 99,24%, contra 78,86% do ADALINE e 71,80% do Perceptron Simples. Ela também foi a única com sensibilidade e especificidade altas ao mesmo tempo (99,59% e 98,36%). Os dois modelos lineares, por sua vez, comportam-se de forma bem diferente entre si.

O Perceptron Simples teve o pior desempenho e, de longe, a maior variabilidade. O desvio-padrão da acurácia foi de 0,1008, e tanto a sensibilidade quanto a especificidade variaram de 0% a 100%. Como a espiral não é linearmente separável, a regra de Rosenblatt nunca para de corrigir os pesos: a cada época o hiperplano é empurrado pelas amostras erradas, e o EQM oscila sem convergir. O resultado final depende apenas de onde o hiperplano estava ao fim da 100ª época. Por isso, sensibilidade e especificidade são fortemente antagônicas (correlação de −0,84 nas 500 rodadas). Em 32,6% das rodadas a sensibilidade foi 1, em geral com especificidade baixa, pois a rede respondeu +1 para quase tudo. A mediana da acurácia (72,14%) é praticamente igual aos 71,4% do classificador trivial, e em 44,2% das rodadas a acurácia ficou abaixo dessa referência.

O ADALINE, ao contrário, é estável (desvio-padrão da acurácia de 0,0234). Ele minimiza o EQM, cujo mínimo é único, e por isso encontra praticamente o mesmo hiperplano em todas as rodadas; a variação que resta vem da partição sorteada. Esse hiperplano, porém, favorece a classe majoritária: sensibilidade de 88,34% e especificidade de apenas 55,26%. A acurácia fica cerca de 7 p.p. acima da referência trivial (só 0,2% das rodadas ficaram abaixo dela), o que é próximo do máximo que uma fronteira linear consegue nesse problema.

A MLP 5-5 resolve o problema: a mediana da acurácia é 99,29%, 69,4% das rodadas ficaram com acurácia de pelo menos 99% e 18,4% acertaram todas as amostras de teste. A cauda inferior da distribuição é curta: só 6,6% das rodadas ficaram abaixo de 98%, e o mínimo foi 93,21%. Como se discute no item seguinte, essas rodadas estão ligadas à instabilidade causada pela taxa de aprendizado alta. A Fig. 8 compara as fronteiras dos três modelos na primeira rodada: as do Perceptron e do ADALINE são retas, e a da MLP acompanha a espiral.

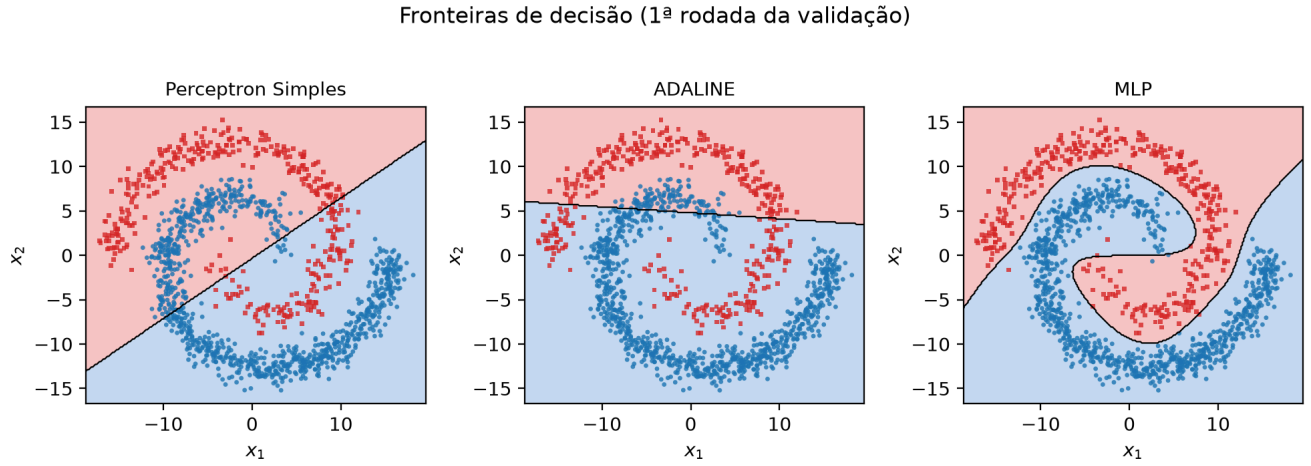


Fig. 8. Fronteiras de decisão dos três modelos treinados na primeira rodada da validação.

5) Rodadas de maior e menor desempenho: As Figs. 9 a 11 mostram, para cada modelo e métrica, a matriz de confusão e a curva de aprendizado das rodadas de maior e de menor valor. Os extremos foram (maior e menor): Perceptron Simples: acurácia 0,8857 (rodada 271) e 0,2500 (rodada 336); sensibilidade 1,0000 (rodada 4) e 0,0000 (rodada 13); especificidade 1,0000 (rodada 5) e 0,0000 (rodada 48). ADALINE: acurácia 0,8536 (rodada 70) e 0,7107 (rodada 453); sensibilidade 0,9521 (rodada 158) e 0,7953 (rodada 108); especificidade 0,7108 (rodada 396) e 0,4217 (rodada 51). MLP: acurácia 1,0000 (rodada 3) e 0,9321 (rodada 239); sensibilidade 1,0000 (rodada 3) e 0,9704 (rodada 292); especificidade 1,0000 (rodada 2) e 0,7733 (rodada 239).

No Perceptron Simples, as rodadas extremas mostram o efeito da não convergência. Todas as curvas de aprendizado oscilam durante as 100 épocas, sem tendência de queda, e as matrizes mudam de um extremo ao outro. Na rodada de menor acurácia (25,00%, rodada 336), o hiperplano final classificou todas as amostras de teste como −1 (sensibilidade de 0%), e só a classe minoritária foi acertada. Na de menor especificidade (rodada 48), ocorreu o oposto: a rede respondeu +1 para tudo, e as curvas ficaram constantes, porque ao fim de todas as épocas o hiperplano estava fora da região dos dados. A rodada de maior sensibilidade (rodada 4) teve especificidade de apenas 6,1%, e a de maior especificidade (rodada 5) teve sensibilidade de 22,4%. Mesmo a melhor rodada em acurácia (88,57%, rodada 271) acertou só 49% da classe −1.

No ADALINE, as curvas de todas as rodadas extremas são suaves e monotônicas e se estabilizam entre 104 e 219 épocas (174 em média), com EQM final em torno de 0,3 no treino e no teste. Os extremos ficam próximos (acurácia entre 71,07% e 85,36%) e se devem à partição sorteada, e não ao treinamento. Na rodada de maior acurácia, por exemplo, o EQM de teste ficou abaixo do de treino, sinal de que o teste recebeu amostras mais fáceis, mais distantes da reta. Em nenhuma rodada a especificidade passou de 71,08%: a fronteira linear sempre sacrifica boa parte da classe −1.

Na MLP, a rodada 3 acertou todas as amostras de teste. A rodada de menor acurácia (93,21%, rodada 239) é também a de menor especificidade (77,33%), e sua curva de aprendizado explica o resultado. Com $\eta = 2$, o EQM apresenta picos de instabilidade ao longo do treinamento (também visíveis nas rodadas de melhor desempenho), dos quais a rede normalmente se recupera. Nessa rodada, porém, um desses picos ocorreu nas últimas épocas, e o treinamento terminou, pelo limite de épocas, com os pesos ainda perturbados. Cerca de 23% da classe −1 passou a ser classificada como +1. A rodada de menor sensibilidade (rodada 292) mostra outro fenômeno: o EQM de teste estaciona perto de 0,04 enquanto o de treino segue caindo até cerca de 10^{-3}, um sobreajuste local da fronteira nessa partição. Guardar os pesos da época de menor EQM de validação, ou reduzir η ao longo do treinamento, provavelmente eliminaria a maior parte da cauda inferior da distribuição da MLP.

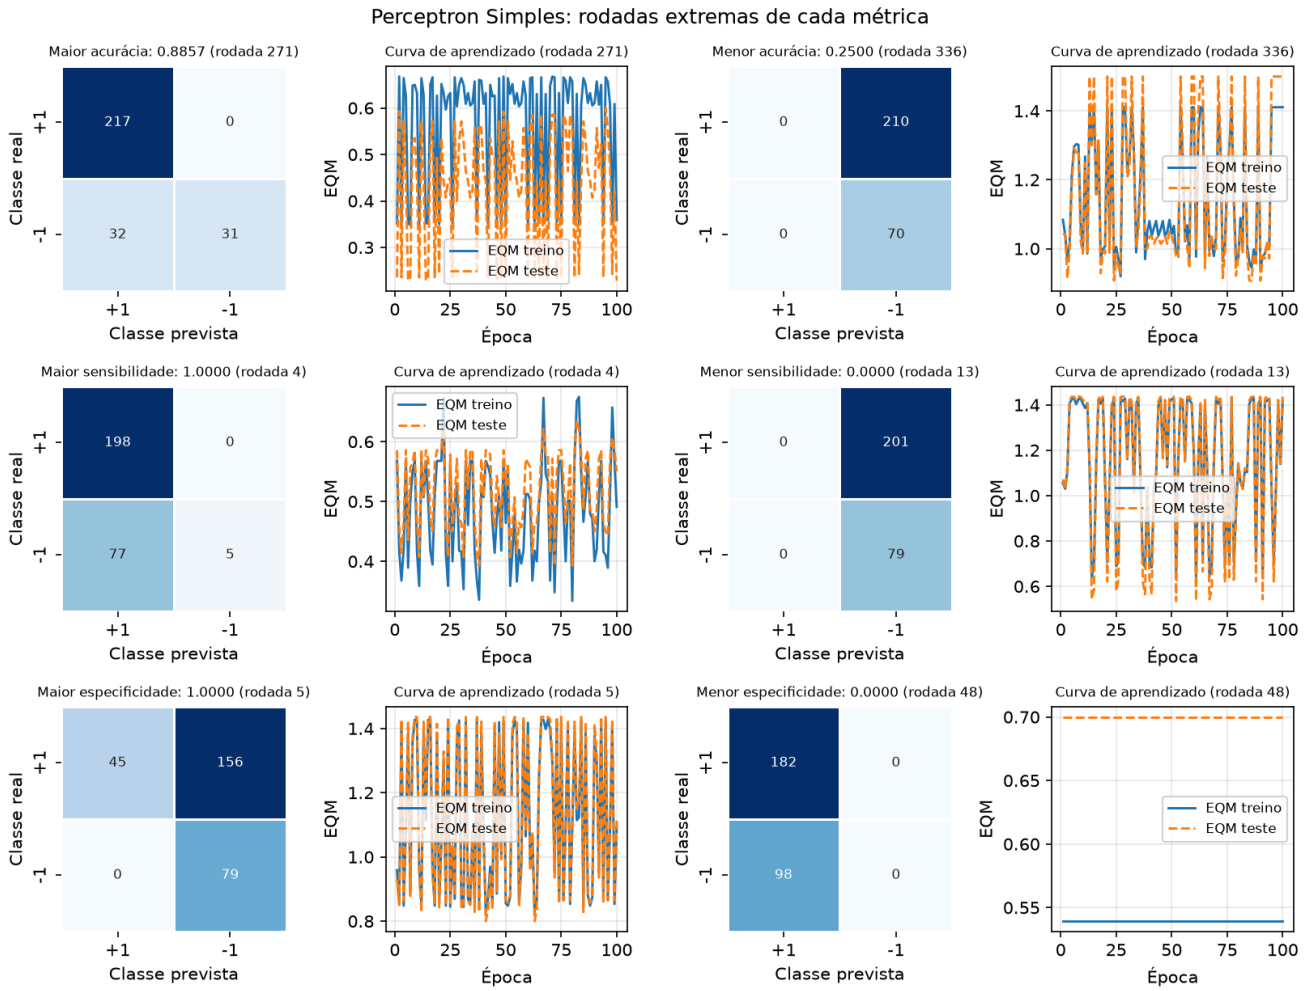


Fig. 9. Perceptron Simples: matrizes de confusão e curvas de aprendizado das rodadas de maior e de menor acurácia (linha 1), sensibilidade (linha 2) e especificidade (linha 3).

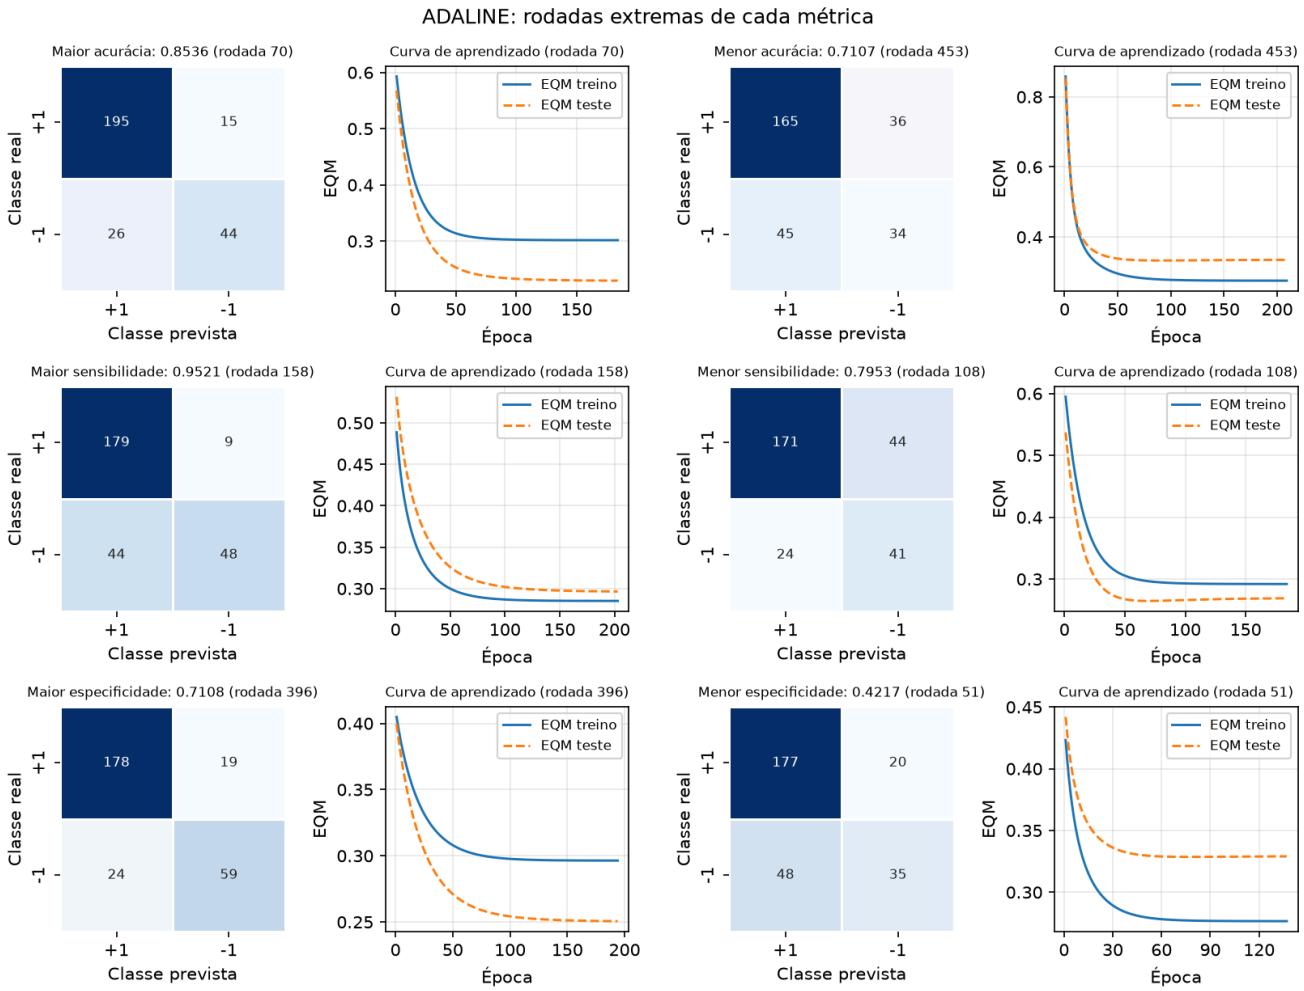


Fig. 10. ADALINE: matrizes de confusão e curvas de aprendizado das rodadas de maior e de menor acurácia (linha 1), sensibilidade (linha 2) e especificidade (linha 3).

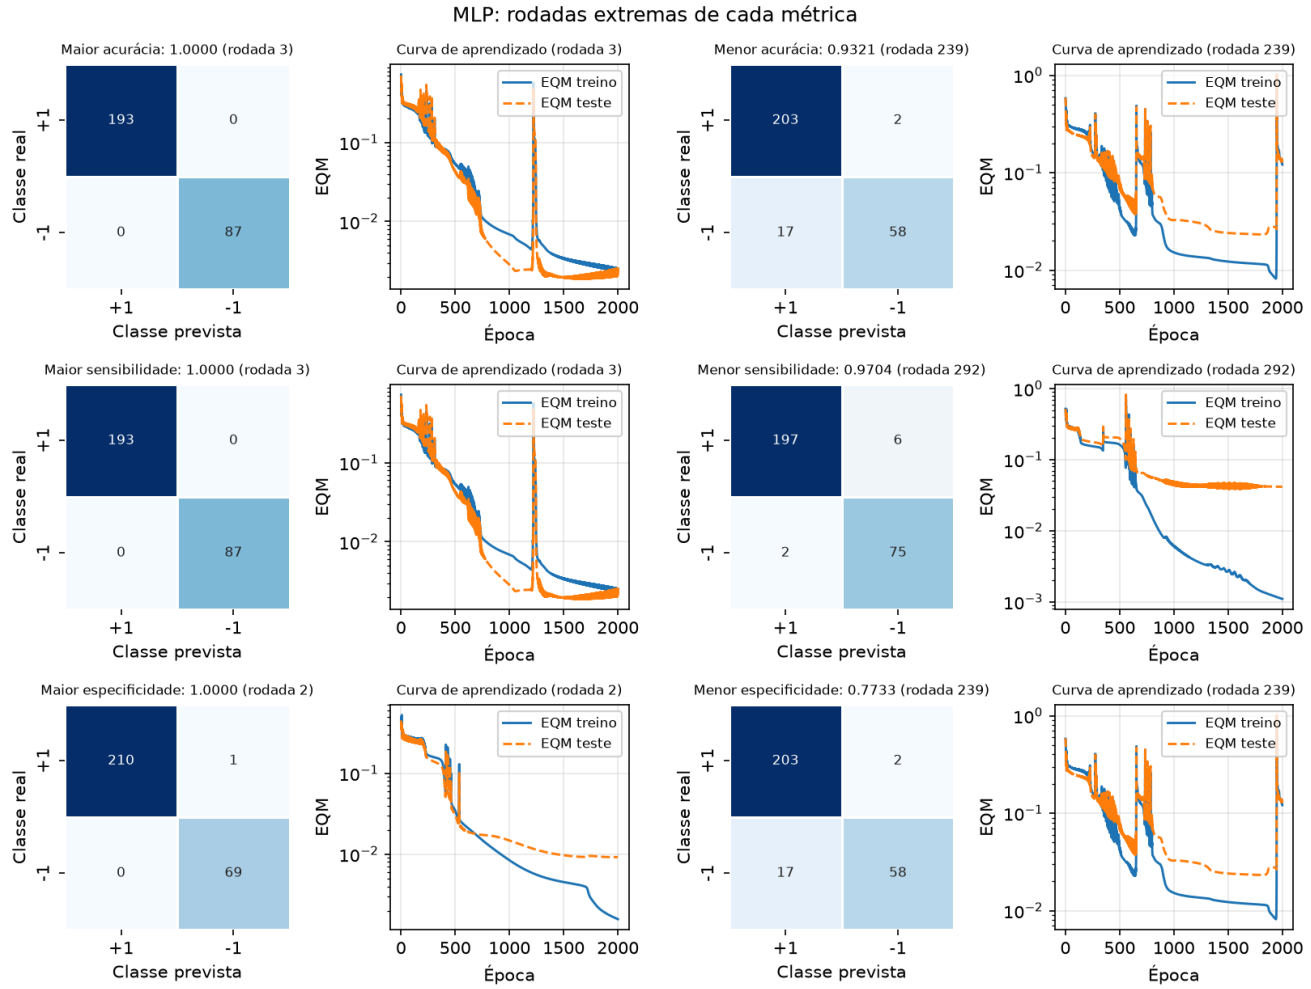


Fig. 11. MLP: matrizes de confusão e curvas de aprendizado das rodadas de maior e de menor acurácia (linha 1), sensibilidade (linha 2) e especificidade (linha 3).

B. Etapa 2 – reconhecimento facial

1) Escolha dos hiperparâmetros: O Perceptron Simples terminou o treinamento sem erros em todas as rodadas, com 7,9 épocas em média (entre 5 e 12). Isso confirma que, com 900 atributos e 512 imagens de treino, o conjunto de treino é linearmente separável. No ADALINE, as quatro configurações testadas ficaram entre 96,61% e 97,14% de acurácia de validação. A taxa $\eta = 0{,}002$, cerca de 1/7 do limite de estabilidade 0,0144, foi a mais precisa e também a mais rápida (25 épocas e 0,68 s em média). Com $\varepsilon = 10^{-4}$, o treinamento levou 111 épocas e a acurácia caiu para 96,61%: continuar minimizando o EQM de treino não melhorou a generalização. A Tabela VI mostra a busca da MLP. Duas lições da Etapa 1 se repetiram: (i) duas camadas ocultas superaram uma camada com número semelhante de pesos (50-50 contra 50), e (ii) a taxa de aprendizado maior tornou instável a rede mais larga (topologia 100 com $\eta = 0{,}1$: 93,49% ± 3,90%). A melhor configuração foi 50-50 com $\eta = 0{,}1$ (97,92%), e nenhuma outra ficou dentro da tolerância de parcimônia.

TABELA VI. MLP NA ETAPA 2: ACURÁCIA DE VALIDAÇÃO (MÉDIA ± DESVIO, 3 PARTIÇÕES)

Topologia	η	Acurácia val.	Pesos	Tempo (s)
20	0,05	0,9714 ± 0,0037	18.440	1,9
20	0,1	0,9714 ± 0,0037	18.440	1,9
50	0,05	0,9740 ± 0,0097	46.070	3,6
50	0,1	0,9714 ± 0,0074	46.070	3,6
100	0,05	0,9714 ± 0,0037	92.120	6,6
100	0,1	0,9349 ± 0,0390	92.120	7,2
50-50	0,05	0,9766 ± 0,0064	48.620	4,3
50-50	**0,1**	**0,9792 ± 0,0074**	**48.620**	**4,2**

2) Validação por Monte Carlo com R = 10 e R = 100: As Tabelas VII e VIII trazem as estatísticas da acurácia nas duas configurações, e a Fig. 12 compara as distribuições.

TABELA VII. ACURÁCIA NA ETAPA 2 COM R = 10 RODADAS

Modelo	Média	Desvio-padrão	Maior valor	Menor valor
Perceptron Simples	0,9703	0,0172	1,0000	0,9453
ADALINE	0,9781	0,0127	0,9922	0,9531
MLP	0,9789	0,0148	1,0000	0,9531

TABELA VIII. ACURÁCIA NA ETAPA 2 COM R = 100 RODADAS

Modelo	Média	Desvio-padrão	Maior valor	Menor valor
Perceptron Simples	0,9780	0,0129	1,0000	0,9453
ADALINE	0,9803	0,0111	1,0000	0,9531
MLP	0,9827	0,0109	1,0000	0,9531

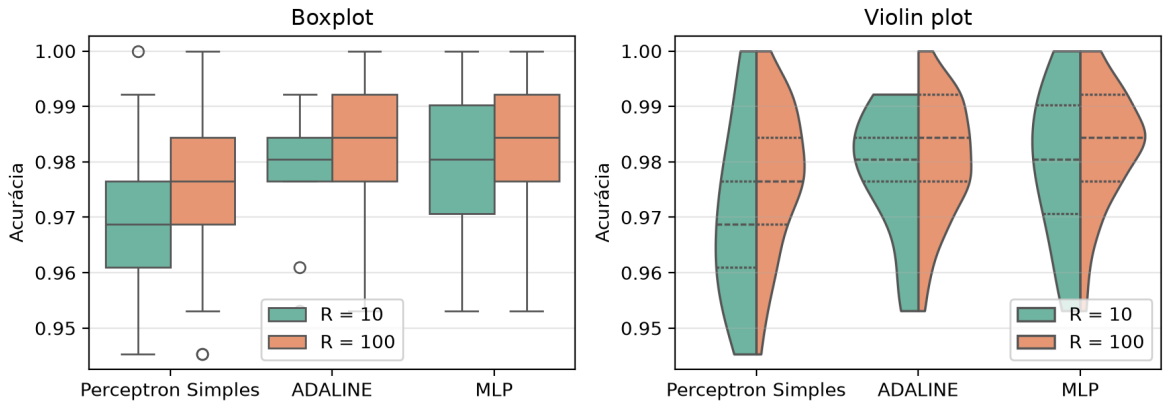


Fig. 12. Distribuição da acurácia dos três modelos com R = 10 e R = 100 rodadas (boxplot à esquerda; violin plot à direita, com os quartis tracejados).

Com R = 100, a ordem das acurácias médias foi MLP (98,27%), ADALINE (98,03%) e Perceptron Simples (97,80%). Ao contrário da Etapa 1, os modelos lineares ficaram muito próximos da MLP. Com p = 900 atributos e apenas 512 imagens de treino, um hiperplano é capaz de separar cada pessoa das demais no treino (o Perceptron chega a zero erros de treino em poucas épocas). Assim, o problema deixa de ser a capacidade do modelo e passa a ser a generalização para as imagens de teste, com poses, expressões e uso de óculos diferentes. Nessa situação, a não linearidade da MLP traz um ganho pequeno. O Perceptron, que para no primeiro hiperplano que separa o treino, sem procurar uma margem, é o que generaliza pior e o que mais varia. O ADALINE, que minimiza o EQM, posiciona melhor o hiperplano.

Como em cada rodada os três modelos usam a mesma partição, as diferenças podem ser avaliadas rodada a rodada. Com R = 100, a MLP superou o ADALINE em 32 rodadas, empatou em 57 e perdeu em 11, com diferença média de 0,24 ± 0,06 p.p. (média ± erro-padrão). Em relação ao Perceptron, a MLP venceu 48, empatou 43 e perdeu 9, com diferença de 0,48 ± 0,08 p.p. Com R = 10, a diferença MLP − ADALINE foi de 0,08 ± 0,18 p.p.: o erro-padrão é maior que a própria diferença, então dez rodadas não bastam para ordenar os dois modelos.

Quanto à estabilidade, o desvio-padrão mede a dispersão das rodadas individuais. Ele é uma propriedade do modelo e da divisão 80/20, e não diminui com R. De fato, ele teve a mesma ordem de grandeza nas duas configurações (Perceptron: 0,0172 e 0,0129; ADALINE: 0,0127 e 0,0111; MLP: 0,0148 e 0,0109). Com R = 10 ele foi um pouco maior, mas também é estimado com apenas dez valores. O que diminui com R é a incerteza da média, medida pelo erro-padrão $s/\sqrt{R}$, que caiu de 0,54 para 0,13 p.p. (Perceptron), 0,40 para 0,11 p.p. (ADALINE) e 0,47 para 0,11 p.p. (MLP), uma redução próxima de $\sqrt{10} \approx 3{,}2$.

Os valores extremos praticamente não mudaram. A rodada de menor acurácia dos três modelos entre as cem já fazia parte das dez primeiras. Só mudou o maior valor do ADALINE (de 99,22% na rodada 5 para 100,00% na rodada 11). Isso é uma coincidência deste sorteio: em geral, com poucas rodadas as partições mais desfavoráveis podem não ser sorteadas, e a faixa de variação fica subestimada. Neste caso, o efeito da escolha de R apareceu sobretudo na média. As dez primeiras partições foram, por acaso, mais difíceis que a média, e com R = 10 as acurácias médias ficaram 0,77 p.p. (Perceptron), 0,22 p.p. (ADALINE) e 0,38 p.p. (MLP) abaixo das de R = 100. A Fig. 13 mostra a média acumulada com o aumento do número de rodadas. Nas primeiras rodadas ela oscila vários décimos de ponto percentual, e as curvas do ADALINE e da MLP se cruzam. A ordem final (MLP > ADALINE > Perceptron) só se fixa a partir da rodada 9, e as três médias só ficam a menos de 0,2 p.p. dos valores finais a partir da rodada 49. Conclui-se que R = 10 fornece uma estimativa grosseira, suficiente para uma primeira verificação, enquanto R = 100 permite comparar modelos cujas acurácias diferem em menos de 1 ponto percentual.

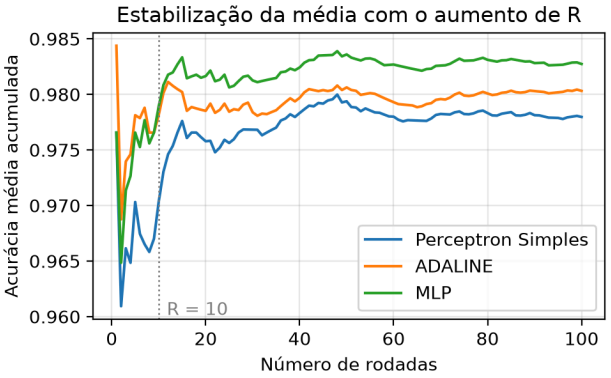


Fig. 13. Acurácia média acumulada ao longo das 100 rodadas. A linha pontilhada marca R = 10.

O custo de treinamento por rodada foi de 0,04 s para o Perceptron, 0,79 s para o ADALINE (28,7 épocas em média) e 5,04 s para a MLP, que usou todas as 1500 épocas em todas as rodadas sem atingir ε. A MLP custa cerca de 120 vezes o tempo do Perceptron e 6 vezes o do ADALINE para um ganho inferior a 1 ponto percentual.

3) Rodadas de maior e menor acurácia: As Figs. 14 a 17 mostram as matrizes de confusão 20 × 20 das rodadas de maior e de menor acurácia, e as Figs. 18 e 19 trazem as curvas de aprendizado correspondentes. Os extremos foram (maior e menor): R = 10: Perceptron 1,0000 (rodada 10) e 0,9453 (rodada 2); ADALINE 0,9922 (rodada 5) e 0,9531 (rodada 2); MLP 1,0000 (rodada 10) e 0,9531 (rodada 2). R = 100: Perceptron 1,0000 (rodada 10) e 0,9453 (rodada 2); ADALINE 1,0000 (rodada 11) e 0,9531 (rodada 2); MLP 1,0000 (rodada 10) e 0,9531 (rodada 2). Para o Perceptron Simples e a MLP, as rodadas extremas com R = 10 são exatamente as mesmas de R = 100 (as dez primeiras rodadas são comuns às duas configurações), e as figuras seriam idênticas. Por isso, apenas as de R = 100 são mostradas, enquanto para o ADALINE são mostradas as duas configurações.

Nas rodadas de maior acurácia, todas as imagens de teste ficam na diagonal. A rodada de menor acurácia foi a mesma para os três modelos (rodada 2), com 7 (Perceptron), 6 (ADALINE) e 6 (MLP) erros em 128 imagens. Isso indica que o desempenho depende mais de quais imagens caem no teste do que do modelo. Nessa rodada, os três modelos erraram imagens das mesmas pessoas (glickman, karyadi, mitchell e sz24), que estão entre as mais difíceis na análise por pessoa apresentada adiante. A confusão karyadi → tammo, por exemplo, aparece nas três matrizes. Os erros ficam espalhados fora da diagonal, com no máximo dois por pessoa, e nenhuma classe inteira é perdida.

Nas curvas de aprendizado, o Perceptron zera o EQM de treino em poucas épocas (entre 5 e 12 nas 100 rodadas) e para, já que o treino é linearmente separável. O EQM de teste estaciona em um patamar muito mais alto na rodada de menor acurácia. O ADALINE reduz os dois EQMs de forma suave e monotônica até atingir o critério $|\Delta EQM| \leq \varepsilon$ (entre 22 e 46 épocas). Na pior rodada, o EQM de teste termina mais de dez vezes acima do de treino. A MLP parte de um EQM próximo de 10 e cai rapidamente para um platô em EQM ≈ 2, que corresponde a todas as 20 saídas próximas de -1 (para cada amostra, 19 dos 20 alvos valem -1). Ela só escapa desse platô após cerca de 100 épocas. Na melhor rodada, as curvas de treino e de teste descem juntas até o fim. Na pior, o EQM de teste estaciona em torno de 0,12 a partir de cerca de 300 épocas, enquanto o de treino continua caindo até cerca de $4 \cdot 10^{-3}$. As épocas restantes apenas ajustam o treino, sem reduzir o erro de teste, o que é um overfitting leve. Uma parada antecipada pelo EQM de validação reduziria bastante o custo da MLP.

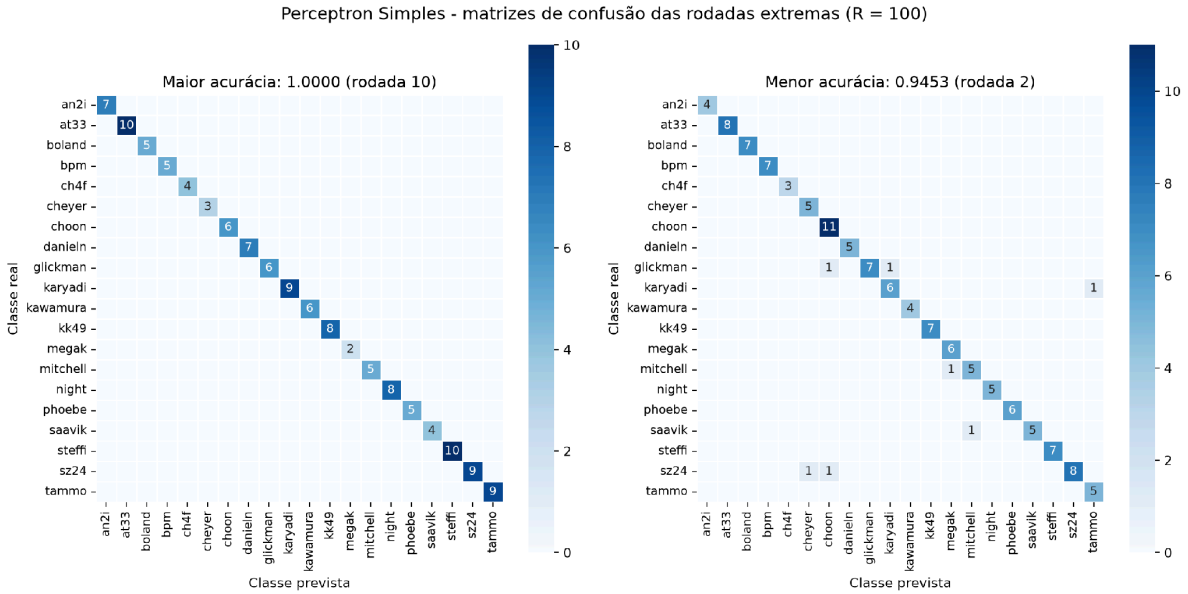


Fig. 14. Perceptron Simples, R = 100: matrizes de confusão das rodadas de maior (esquerda) e de menor (direita) acurácia. Linhas: pessoa real; colunas: pessoa prevista.

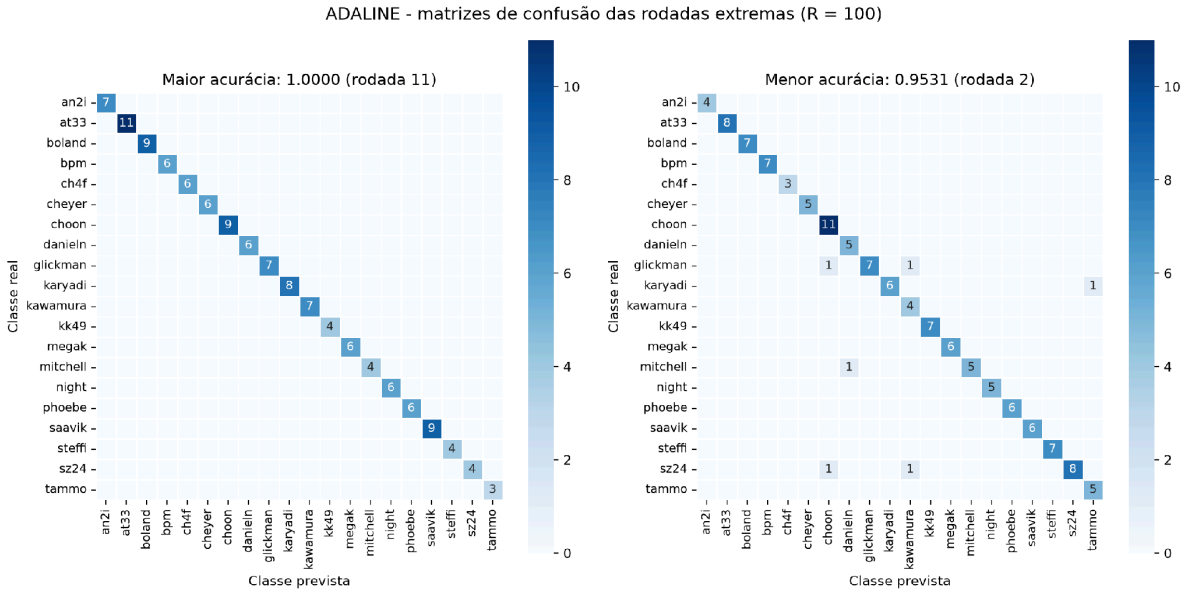


Fig. 15. ADALINE, R = 100: matrizes de confusão das rodadas de maior (esquerda) e de menor (direita) acurácia. Linhas: pessoa real; colunas: pessoa prevista.

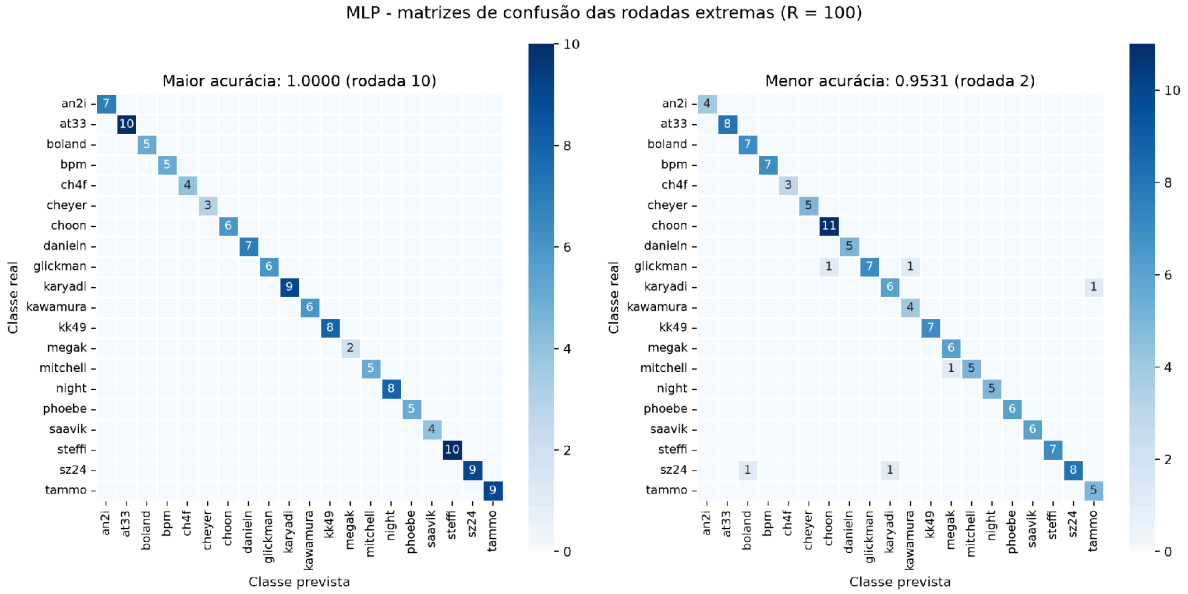


Fig. 16. MLP, R = 100: matrizes de confusão das rodadas de maior (esquerda) e de menor (direita) acurácia. Linhas: pessoa real; colunas: pessoa prevista.

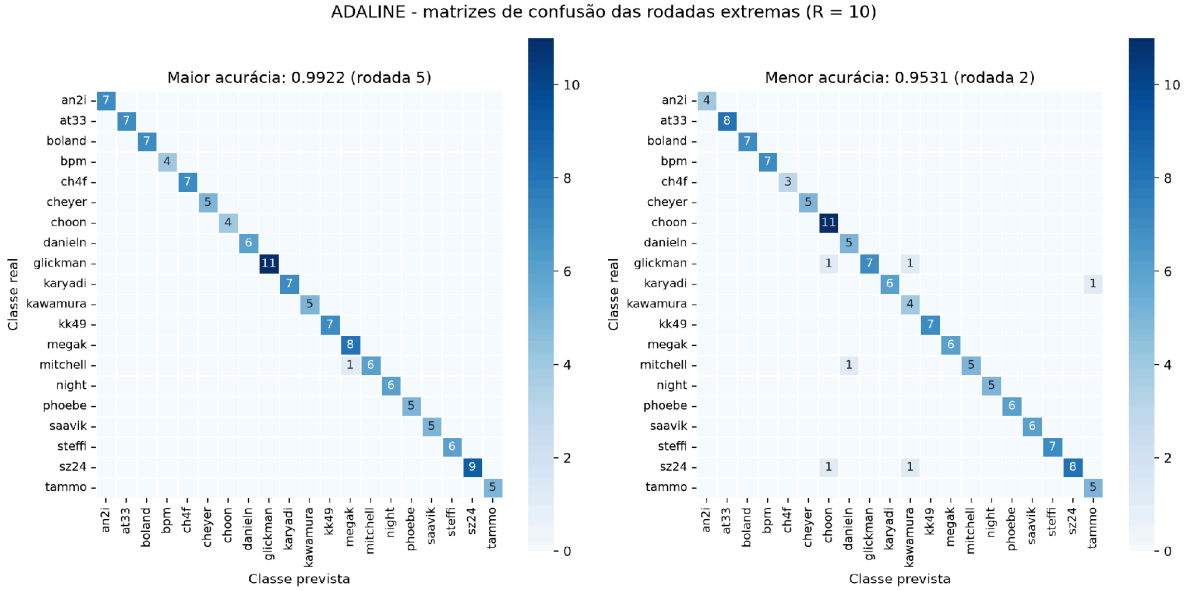


Fig. 17. ADALINE, R = 10: matrizes de confusão das rodadas de maior (esquerda) e de menor (direita) acurácia. Linhas: pessoa real; colunas: pessoa prevista.

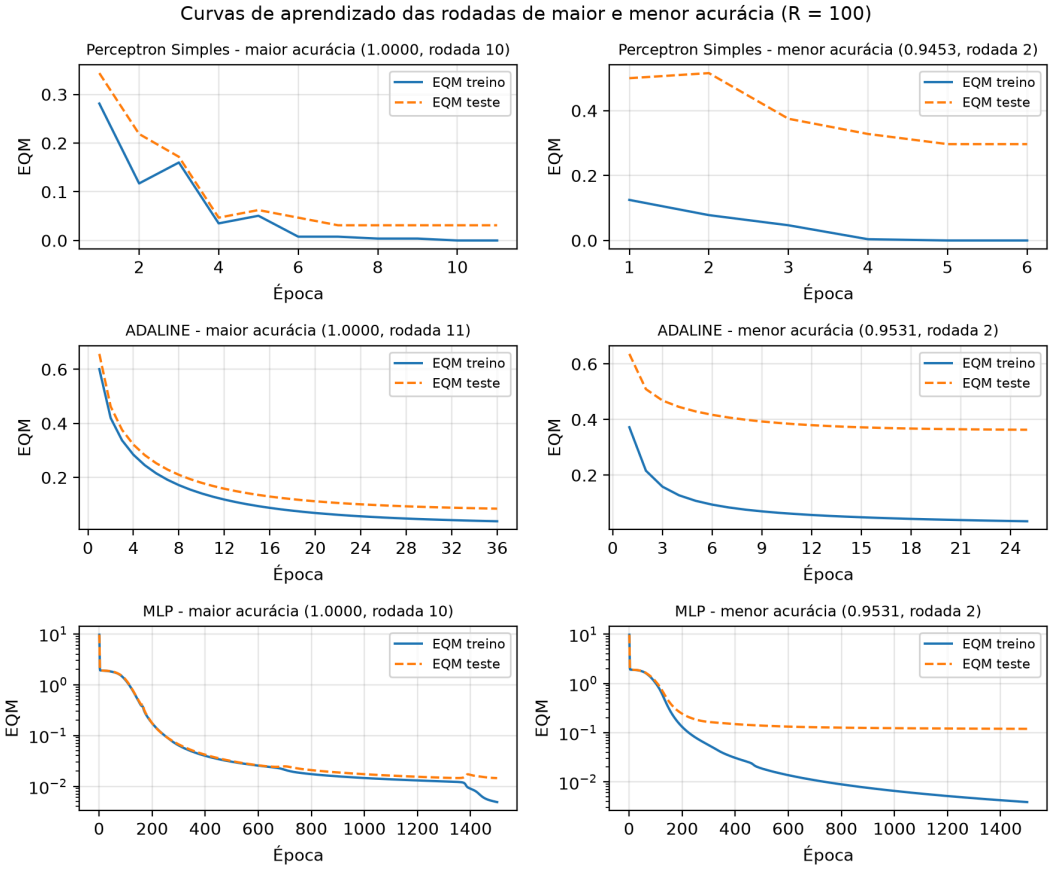


Fig. 18. Curvas de aprendizado (EQM de treino e de teste por época) das rodadas de maior e de menor acurácia, R = 100. Na MLP o eixo vertical está em escala logarítmica.

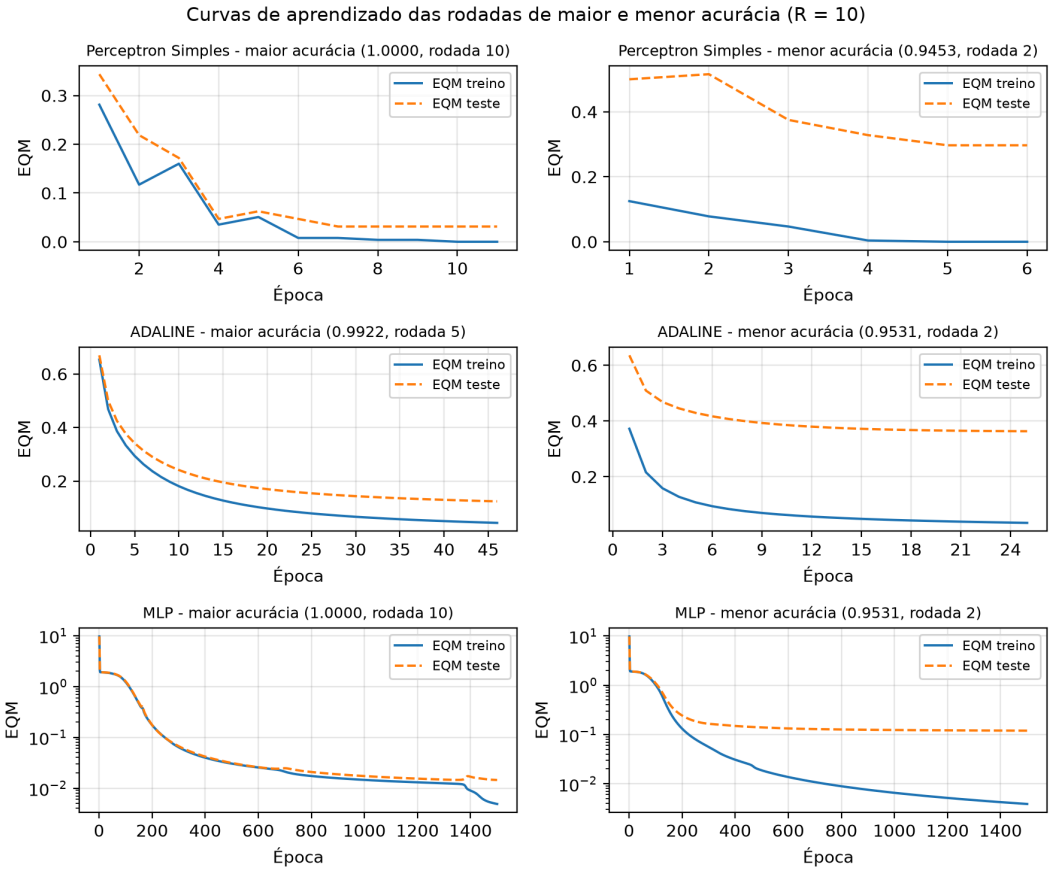


Fig. 19. Curvas de aprendizado (EQM de treino e de teste por época) das rodadas de maior e de menor acurácia, R = 10. Na MLP o eixo vertical está em escala logarítmica.

4) Análise dos erros por pessoa: Para identificar quais pessoas são mais difíceis, as matrizes das 100 rodadas foram somadas (12.800 classificações de teste por modelo), e a Fig. 20 mostra a taxa de acerto de cada pessoa. As dificuldades se concentram nas mesmas pessoas para os três modelos: as piores taxas médias foram de sz24 (92,9%), megak (93,6%), mitchell (94,6%) e tammo (95,3%). As três pessoas mais difíceis com R = 10 foram sz24, mitchell e megak, o que mostra que esse padrão já aparecia com poucas rodadas. Por outro lado, 7 pessoas foram reconhecidas em 100% dos casos pelos três modelos (boland, bpm, ch4f, cheyer, kk49, night e steffi). Os modelos acertaram 100% das imagens de

7 (Perceptron), 9 (ADALINE) e 10 (MLP) pessoas. Somando os três modelos, as confusões mais frequentes (pessoa real → prevista) foram karyadi → tammo (38 vezes), at33 → bpm (31 vezes), choon → glickman (31 vezes), sz24 → choon (28 vezes) e sz24 → kawamura (28 vezes).

A correlação de Pearson entre as taxas de acerto por pessoa foi de 0,95 (Perceptron × ADALINE), 0,95 (Perceptron × MLP) e 0,97 (ADALINE × MLP). Os três classificadores, lineares ou não, erram essencialmente nas mesmas pessoas e frequentemente trocam os mesmos pares. Portanto, a dificuldade vem das próprias imagens, e não do modelo. Uma explicação provável é que, reduzidas a 30 × 30 pixels e normalizadas, as imagens dessas pessoas em certas poses ou com óculos escuros ficam mais parecidas com as de outra pessoa do que com as suas em outra pose. As confusões são, em geral, assimétricas: apenas 37% dos erros têm correspondente no sentido inverso. Por exemplo, at33 → bpm ocorreu 31 vezes, e bpm → at33 nenhuma. Assim, a região de decisão de uma pessoa invade a de outra sem que o contrário aconteça. A exceção mais clara é o par karyadi ↔ tammo, confundido nos dois sentidos (38 e 26 vezes), o que sugere duas pessoas realmente parecidas nessa resolução.

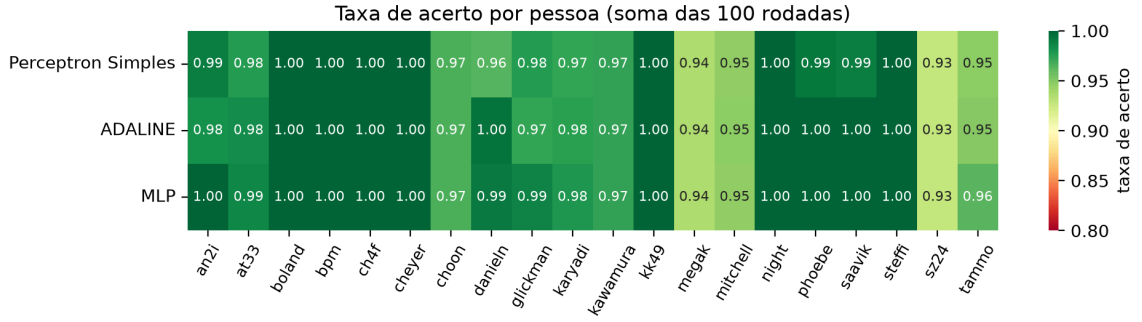


Fig. 20. Taxa de acerto por pessoa e por modelo, obtida da soma das matrizes de confusão das 100 rodadas.

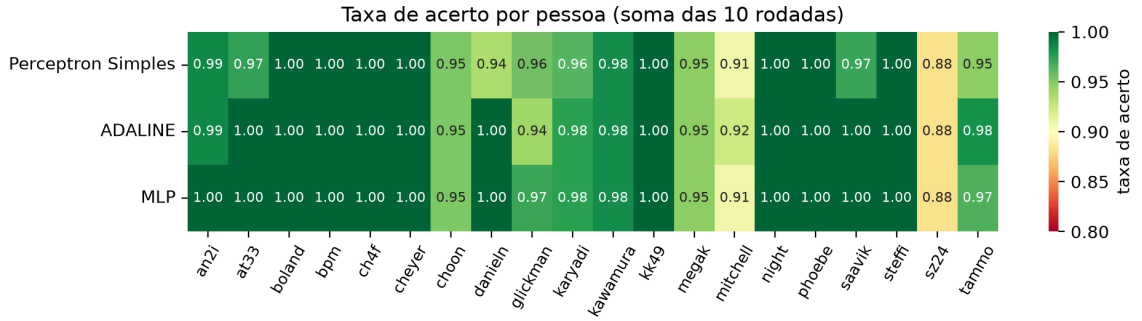


Fig. 21. Taxa de acerto por pessoa e por modelo, obtida da soma das matrizes de confusão das 10 rodadas.

IV. Conclusões

Os experimentos confirmaram, com números, a diferença entre modelos lineares e não lineares. Na espiral, que não é linearmente separável, o Perceptron Simples (acurácia média de 71,80%) e o ADALINE (78,86%) ficaram próximos do classificador trivial que sempre responde +1 (71,4%): o primeiro praticamente o iguala, e o segundo o supera em apenas 7 p.p. O Perceptron mostrou alta instabilidade, porque sua regra nunca converge nesse caso. O ADALINE é estável, mas tende a favorecer a classe majoritária (especificidade de 55,26%). A MLP 5-5, com tangente hiperbólica, atingiu 99,24% e modelou a fronteira em espiral.

O estudo de topologias mostrou o papel da capacidade da rede. A rede com dois neurônios ocultos sofre underfitting, com erros altos e iguais no treino e no teste. A rede com três camadas de 60 neurônios, treinada sem parada antecipada, memoriza o treino na maioria das partições, e em algumas delas o erro de teste fica centenas de vezes maior que o de treino (overfitting). Ela também varia mais entre partições e tem custo computacional muito maior. A escolha dos hiperparâmetros por busca em grade com várias partições e a regra de parcimônia evitaram as duas situações. A validação também revelou que taxas de aprendizado altas aceleram a MLP, mas provocam picos de instabilidade no EQM. Quando um desses picos coincide com o fim do treinamento, a rede termina com pesos piores, o que explica a rodada de pior desempenho. Uma parada antecipada que guarde os melhores pesos resolveria esse problema.

No reconhecimento facial, a alta dimensionalidade (900 pixels para 512 imagens de treino) tornou o problema quase linearmente separável. Os três modelos superaram 97% de acurácia média (com R = 100: Perceptron 97,80%, ADALINE 98,03% e MLP 98,27%). A MLP foi a mais precisa, mas por pouco e com custo muito maior, e o ADALINE ofereceu a melhor relação entre desempenho e custo. As mesmas pessoas foram as mais difíceis para todos os modelos, o que aponta para a variabilidade das imagens, e não para o classificador. Quanto à divergência do enunciado, a execução com R = 10 e com R = 100 mostrou que o desvio-padrão por rodada é praticamente o mesmo nas duas configurações, mas a incerteza da média cai cerca de $\sqrt{10} \approx 3{,}2$ vezes (na MLP, de 0,47 para 0,11 p.p.). Com dez rodadas, a diferença entre a MLP e o ADALINE fica dentro da incerteza, e só com cem rodadas é possível ordená-los com segurança.

Como trabalhos futuros, sugere-se usar parada antecipada baseada em um conjunto de validação, treinar a MLP por mini-lotes para reduzir o custo, e, no reconhecimento facial, reduzir a dimensionalidade, por exemplo com PCA, além de ampliar o conjunto de treino com variações das imagens para diminuir a confusão entre as pessoas mais difíceis.

Referências

[1] S. Haykin, Neural Networks and Learning Machines, 3rd ed. Upper Saddle River, NJ, USA: Pearson, 2009.

[2] F. Rosenblatt, "The perceptron: a probabilistic model for information storage and organization in the brain," Psychological Review, vol. 65, no. 6, pp. 386–408, 1958.

[3] B. Widrow and M. E. Hoff, "Adaptive switching circuits," in IRE WESCON Convention Record, part 4, pp. 96–104, 1960.

[4] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," Nature, vol. 323, pp. 533–536, 1986.

[5] Y. LeCun, L. Bottou, G. B. Orr, and K.-R. Müller, “Efficient BackProp,” in Neural Networks: Tricks of the Trade, LNCS 1524. Berlin, Germany: Springer, 1998, pp. 9–50.

[6] T. M. Mitchell, Machine Learning. New York, NY, USA: McGraw-Hill, 1997.

[7] P. C. S. Barbosa, “Inteligência Artificial Computacional: slides de aula,” Universidade de Fortaleza (UNIFOR), Fortaleza, Brasil, 2026.